



İSTİNYE ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

YAZ492: BİTİRME TEZİ 2
İLK RAPOR

Nisan 2022

PROJE BAŐLIĐI

Paralel Mimarilerde Seyrek Alt Üçgen Matris Çözümü için
Graf Parçalaması ile Yük Dengelemesi

PROJE YAZARI

Abdülkadir Furkan Yıldız - 190701145

DANIŐMAN


Dr. Öğr. Üyesi Buse Yılmaz

ÖZET

Chainbreaker paralel mimarilerde Seyrek Alt Üçgen Çözümü'nü optimize eden bir çerçevedir. Çerçevenin önemli bir modül yapılacak bağımlılık grafi dönüşümleri için stratejiler bütünü ve stratejilerin uygulanacağı seviyeleri belirleyen strateji koleksiyonu ve strateji seçme modülüdür. Projenin amacı, grafi aşağıdaki hedeflere ulaşılacağı şekilde dönüştürerek, seviyeler arasında ve içinde yük dengelemesini sağlayacak stratejileri ve uygulanacakları seviyeleri belirlemektir. Bu çalışmada, bir seyrek alt üçgen matrisin sınırlı paralellik gösteren parçalarının paralellik derecesini artırmak için bağımlılık grafini dönüştüren Chainbreaker çerçevesi için bir strateji koleksiyonu geliştirilecektir.

- Düşük paralellik derecesine sahip seyrek alt üçgen matris parçalarının paralellliğini graf dönüşümü ile artırarak, seyreklik yapısını daha homojen hale getirmek.

- Senkronizasyon noktalarına olan ihtiyacı azaltmak



Şekil 1. Seyrek Alt Üçgen Matrislerin $Lx = b$

İÇİNDEKİLER

GİRİŞ	1
LİTERATÜR TARAMASI.....	2
METOT VE YAPILACAK TESTLER.....	3
PROJE İLE İLGİLİ İLK RAPORDAN ARA RAPORA KADAR YAPILAN İŞLER	4
PROJE İLE İLGİLİ SONRAKİ RAPORA KADAR YAPILACAKLAR VE BEKLENEN SONUÇLAR.....	5
KAYNAKÇA.....	6
FİGÜR LİSTESİ.....	

FIGÜR LİSTESİ


E olduğunuz resimler var ise buradaki listede gözükmesi gerekmektedir.

Şekil 1: Seyrek Alt Üçgen Matrisi $Lx = b$	0
Şekil 2: Yeniden Yazma Yöntemi.....	1

GİRİŞ

Bu çalışmanın amacı Chainbreaker çerçevesinin efektif olarak Seyrek Alt Üçgen Çözümü için optimizasyon yapabilmesine olanak sağlayacaktır. Bunun için matrisin bağımlılık grafının mimarinin çekirdeklerine dengeli biçimde dağıtılması gerekmektedir.

Bu çalışma bağımlılık grafi üzerinde ki dönüşümleri modelleyerek bu dengelemeyi yapacaktır. Graf dönüşümü göz önüne alındığında, Chainbreaker'ın önerdiği yeniden yazma yöntemi ile matrisin paralellik derecesi az olan parçalarını dönüştürerek, bu parçaların paralellik derecesini artırmaktadır. Satır bağımlılıklarını esneterek ya da tamamen ortadan kaldırarak, daha çok çekirdek kullanımına olanak sağlar. Buna ek olarak, ince seviyeler bu yöntemler ile tamamen ortadan kaldırılarak senkronizasyon bariyeri ihtiyacını azaltmış olur.



Şekil 2. Yeniden Yazma Yöntemi

LİTERATÜR TARAMASI

[1]'de Gauss Eliminasyonunda Markov Karar Sürecinin öğrenilmesi adına yapılan bir yaklaşımdan bahsedilmektedir. Burada özellikle Reinforcement Learning'in bir öğrenim şekli olan Q-Learning tekniği ele alınmıştır. Burada birden fazla Q-learning tekniği okuyucuya önerilmiştir. Bunlar minimum degree ordering, task scheduling and adaptive pivoting. Öğrenmeye dayalı bir algoritma olan bu Teknik ile seyrek çözücüde performansı artırmaya dayalı bir şekilde kullanılmıştır.

Bizim projemizde Seyrek alt üçgensel bir matrisler üzerinde işlem yaptığımızdan dolayı genel olarak burada Gauss Eliminasyonu ile yeniden yazma işlemlerini gerçekleştiriyoruz. [2] burada ki kitabın Chapter 3'ünde Sonlu Markov Karar Süreçlerini anlatarak bizlere bu konuda daha güzel örnekler üzerinden RL ile Markov'u beraber nasıl kullanabileceğimiz konusunda eğitmektedir.

[2]'nin Chapter 3'ünde ilk önce RL'in çalışma prensiplerinde Agent- Environment ilişkisinden bahsedilmektedir. Daha sonrasında ise Ödüller ve Cezalar üzerinden durulmaktadır. RL'de eğer istenilen işlemler sağlanıyorsa ödül sağlanmıyor ise ceza alarak ajanımız bir oyun oynar gibi eğitilmektedir. Burada verilen bir örnekte Çöp Toplama robotunun hareketleri üzerinden bir anlatım yapılmıştır. Robotumuzun şarjının 2 adet durumu vardır bunlar "high,low" ve robotumuz 3 tane işi yapabiliyor "search, wait, recharge". Eğer robotumuzun pili "high" ise "search,wait" işlemlerini "low" ise 3 işlemide yapabiliyor, eğer "search" işlemini yaparken şarjı biterse ceza alıyor, her topladığı çöp için ise bir adet ödül puanı alıyor. Robotun çalışma şekli Reinforcement Learning ile bu şekilde kuruluyor ve eğitiliyor. Burada Markov Karar Süreçlerini ise bu durumların koşullu olarak oluşma olasılıkları üzerinden hesaplanarak yapılıyor.

Biz ise bu örnekte olduğu gibi problemimizi bir agent-environment ilişki kurarak gerekli tüm hesaplamaları ve kurallarımızı bu agent üzerinden Markov Karar Süreçlerini kullanarak hesaplatmayı ve bu hesaplamaları kullanarak yeniden yazma işlemlerini gerçekleştirmeyi hedefliyoruz.

METOT VE YAPILACAK TESTLER

Bu proje için geliřtirdiđimiz en son algoritma 3 adet kritere sahip ve bu kriterler üzerinden gerekli iřlemler yapılarak matrisimizi optimal hale getirmeyi amalamaktadır. Bu algoritma her bir row'u rewrite ederken bakması gereken 3 adet kriter vardır bunlar:

1-avgCostPerLevel – Yani her rewrite ettiđimiz leveledaki cost deđerimiz ortalama cost deđerimizden büyük veya küçük mü ?

2-avgInPerRow – Ortalama cost deđerimizden küçük levellarda ki ortalama row sayısı. Bu deđerden küçük mü büyük mü ?

3-avgIndegrePerLevel – Ortalama cost deđerimizden küçük levellardı indegree sayılarının ortalaması. Bu deđerden küçük mü büyük mü ?

Eđer bu deđerlerden küçük ise bir üstte ki levela gider ve orada bu kriterleri arar. Eđer bu kriterlerden herhangi birisi sağlanmaz ise o row en son sağlanan levela yazılır. Bu şekilde daha optimal bir matris elde etmek istenmektedir. Bu algoritma için lung_2 isimli matris kullanılmaktadır.

PROJE İLE İLGİLİ YAZ491'IN SON RAPORUNDAN YAZ492 İLK RAPORUNA KADAR YAPILAN İŞLER

En son ki raporda yazılı olan algoritma biraz geliştirilerek bu algoritma BŞARIM 2022 konferansı için bildiri olarak gönderildi ve yakın zamanda bu bildiri yakın zamanda kabul görmüştür. Buraya gönderdiğimiz algoritma en son raporda ki algoritmanın biraz daha geliştirilmiş halidir. Bu algoritma genel olarak şu şekilde çalışmaktadır :

Algoritma ince seviyeler arasında yeniden yazma işlemini uygular. İnce seviyeler, toplam maliyeti $avgLevelCost$ 'tan daha küçük olan seviyelerdir. İnce seviyelerin en alt seviyesinden başlayarak, bu seviyeler yeniden yazdığımız seviyenin maliyeti $avgLevelCost$ 'a ulaşana kadar üst seviyelere yeniden yazılır. Bu nedenle, seviye sayısını azaltmak için kaynak seviyeleri silinir ve hedef seviyelerin maliyetleri $avgLevelCost$ 'a yüklenir. Kaynak ve hedef seviyelerine karar vermek için maliyetleri gösteren $costMap$ adında bir tablo tutuyoruz. Bir satırın orijinal olarak bulunduğu seviyeden başlıyoruz ve her seviye 1'de, seviyeye kadar yeniden yazılmış gibi maliyetini hesaplıyoruz. Daha sonra bir budama işlemi ile bu seviyelerde ki surların konumları kesinleşir.

Bu algoritmadan sonra daha efektif olması açısından yeni bir algoritma daha oluşturduk ve şuan bu algoritmanın koda dökülmesi aşamasındayız. Bu algoritmanın çalışma prensibi şu şekildedir :

Öncelikli olarak Ortalama Seviye Maliyeti ($avg. level cost$), Ortalama Giren Düğüm Derecesi ($avg. indegree per row$), (Yeniden Yazılacak Seviyelerde) Seviye Başına Düşen Ortalama Row Sayısı ($avg. rows per level in levels to be rewritten$) bu kriterler hesaplanır.

Daha sonrasında yeniden yazılacak seviyeler Ortalama Seviye Maliyeti'ne göre belirlenir. En alt seviyelerden başlayarak ;

- a. Satırın düğüm derecesi, Ortalama Giren düğüm derecesinden küçük ise,
- b. Rewrite edilen seviyenin maliyeti, ortalama seviye maliyetinden küçük,
- c. Rewrite edilen seviyenin satır sayısı, Seviye başına düşen ortalama row sayısından küçük ise,

Bu kriterlerin hepsi sağlandığı sürece row 'u bir üst seviyeye taşırız. Kriterlerden herhangi biri sağlanmaz ise kriterlerin sağlandığı en son ki satıra yazılır.

PROJE İLE İLGİLİ SONRAKİ RAPORA KADAR YAPILACAKLAR VE BEKLENEN SONUÇLAR

Final Raporuna kadar en son yazdığımız algoritmayı tamamlayıp daha sonrasında farklı veri setleri ile bu algoritmanın test edilmesini sağlayacağız. Bu algoritma dışında bu problemimizi Reinforcement Learning ve Markov Decision Poces kullanarak nasıl çözebiliriz ? Sorularına yanıt arayarak gerekli literatür taramalarını yapıp daha sonrasında RL ve MDP'yi kullanarak bir algoritma kurmak amaçlanmaktadır. Bunlar üzerinden kurulan algoritmanın mantıksal olarak daha optimal bir yaklaşım ve sorunun çözümüne daha yakın olması amaçlanmaktadır.

KAYNAKÇA

Kaynakça Chicago formatında eklenmelidir.

- [1] Yingshi Chen. "LearningThe Markov Decision Process In The Sparse Gaussian Elimination." arXiv: 2109.14929v1 30 Sep 2021
- [2] Richard S. Sutton and Andrew G. Barto,. Reinforcement Learning. 2016
- [3] Christian Schulz. "High Quality Graph Partitioning" Doktora Tezi, Karlsruher Instituts für Technologie, 2013.
- [4] John E. Savage and Markos G. Wloka. "Parallelism in Graph-Partitioning" Journal of Parallel and Distributed Computing 13(1991): 257-272.
- [5] Buse Yılmaz, Graph Transformation and Specialized code Generation For Sparse Triangular Solve(SpTRSV), 2103.11445v1, 21 Mart 2021